

Análisis de Artistas Billboard con Árboles de Decisión

Diego Covarrubias Garcia

31 de marzo de 2025

1. Introducción

Este informe presenta un análisis de datos de artistas que aparecieron en el Billboard, utilizando árboles de decisión para predecir si una canción llegará al top. Los árboles de decisión son modelos predictivos que dividen recursivamente el espacio de características, siendo particularmente útiles para:

- Interpretación visual de las reglas de decisión
- Manejo de variables categóricas y numéricas
- Identificación de relaciones no lineales
- Selección automática de características importantes

2. Metodología

2.1. Preparación de Datos

Comenzamos cargando y explorando el conjunto de datos:

```
artists_billboard = pd.read_csv("artists_billboard_fix3.csv")
print(artists_billboard.shape)
artists_billboard.head()
```

2.2. Análisis Exploratorio

Realizamos visualizaciones para entender las distribuciones:

```
sb.catplot(x='artist_type', data=artists_billboard,
           kind="count", hue='artist_type', palette="Set2")
sb.catplot(x='mood', data=artists_billboard,
           kind="count", aspect=3, palette=palette)
sb.catplot(x='tempo', data=artists_billboard,
           hue='top', kind="count", aspect=3)
```

2.3. Preprocesamiento

Transformamos variables categóricas a numéricas:

```
# Mapeo de variables categoricas
artists_billboard['moodEncoded'] = artists_billboard['mood'].map({
    'Energizing':6, 'Empowering':6, 'Cool':5, ...}).fillna(0).astype(int)
```

Calculamos la edad de los artistas:

```
def calcula_edad(anio, cuando):
    cad = str(cuando)
    momento = cad[:4]
    if anio == 0.0:
        return None
    return int(momento)-anio
```

2.4. Modelado con Árbol de Decisión

Implementamos validación cruzada para encontrar la profundidad óptima:

```
cv = KFold(n_splits=10)
accuracies = []
max_attributes = len(list(artists_encoded))
depth_range = range(1, max_attributes + 1)

for depth in depth_range:
    tree_model = tree.DecisionTreeClassifier(
        criterion='entropy',
        min_samples_split=20,
        min_samples_leaf=5,
        max_depth=depth,
        class_weight={1: 3.5}
    )
    # Validación cruzada...
```

3. Resultados

3.1. Preprocesamiento

- Edad promedio: 31.2 años (Desviación: 6.8 años)
- Rango para valores nulos: 24 a 38 años

Figura 1: Distribución de edades (naranja=no top, azul=top, verde=imputado)

3.2. Desempeño del Modelo

La mejor precisión promedio se obtuvo con profundidad=4:

Cuadro 1: Resultados por Profundidad

MaxDepth	AverageAccuracy
1	0.55
2	0.55
3	0.56
4	0.65
5	0.62
6	0.64
7	0.64

Precisión final en entrenamiento: 68.98 %

3.3. Predicción de Ejemplo

Para el caso de "Havana" de Camila Cabello:

```
x_test.loc[0] = (1,5,2,4,1,0,3) # mood=5, tempo=2, genre=4, etc.
y_pred = decision_tree.predict(x_test.drop(['top'], axis = 1))
# Prediccion: [1] (llega al top)
# Probabilidad: 68.98 %
```

4. Conclusión

El análisis reveló:

- El modelo alcanzó 68.98 % de precisión con profundidad=4
- Las características más importantes fueron género, estado de ánimo y tipo de artista
- Artistas urbanos/pop con mood energético tienen mayor probabilidad de llegar al top
- La edad óptima ronda los 24-30 años (edadEncoded=1)

Limitaciones y trabajo futuro:

- Mayor cantidad de datos para mejorar la generalización
- Experimentar con otros algoritmos (Random Forest, XGBoost)
- Incorporar características de texto de las letras
- Considerar tendencias temporales